

Università degli Studi di Palermo Dipartimento di Ingegneria <i>Direttore: prof. Antonino Valenza</i>	dipartimento di ingegneria unipa
---	---

CORSO DI BIG DATA — MODULO ANALISI PER I BIG DATA

Prova pratica al calcolatore

Si consideri il data set presente nel file **obesity.csv** costituito da 2111 campioni descritti da 16 feature (sia numeriche continue che categoriche) relative alle caratteristiche fisiche e alle abitudini alimentari dei soggetti, e una label multiclasse target (denominata *NObesydad*) con valori qualitativi distribuiti su 7 distinte classi di peso corporeo.

1.	Caricare il dataset obesity.csv. Effettuare la corretta codifica della label target (Label Encoding sulle 7 classi discrete) e la codifica opportuna delle feature categoriche (One-Hot Encoding). Suddividere il dataset estraendo un test set stratificato pari al 15% dei dati, mantenendo il restante 85% come training/development set. Gestire gli eventuali dati mancanti tramite opportuna tecnica di imputazione (fittata esclusivamente sul training set) e procedere allo scaling (standardizzazione con media nulla e varianza unitaria) delle feature numeriche. Infine, eseguire la selezione e riduzione delle feature tramite Linear Discriminant Analysis (LDA) proiettando i dati nel sottospazio discriminante ammissibile (con numero di componenti non superiore a 6).
	punti 8

2.	Implementare un classificatore ad albero d'insieme Random Forest per il data set curato come al punto precedente, ottimizzandone le prestazioni tramite Grid Search con cross-validation a 5 fold stratificata sui seguenti iperparametri: • n_estimators: [50, 100, 200] • max_depth: [None, 5, 10, 15] • min_samples_split: [2, 5, 10] • criterion: ['gini', 'entropy'] Usare l'accuracy come metrica di scoring della griglia e stampare a video la migliore combinazione di iperparametri individuata, il punteggio medio di cross-validation ottenuto dal miglior modello e la test accuracy registrata in fase di predizione sul test set indipendente.
	punti 8

3.	Implementare una rete neurale convoluzionale 1D (Conv1D) che esegua la classificazione multiclasse sulle 7 categorie a partire dalle feature ridotte ottenute da LDA al punto 1. Si effettui il corretto rimodellamento (reshape) delle matrici di dati in tensori 3D di forma (<i>batch_size</i>, <i>canali</i>, <i>lunghezza</i>) impostando un singolo canale in ingresso. La rete dovrà contenere: • Almeno due layer convoluzionali 1D (con filtri crescenti da 32 a 64 e padding opportuno)
----	--

	intervallati da Batch Normalization e funzioni di attivazione non lineari ReLU; • Uno strato di pooling (max pooling 1D o adaptive average pooling); • Un blocco fully-connected finale con opportuno tasso di Dropout ($p = 0.3$) e strato lineare di classificazione a 7 uscite. La rete sarà addestrata con ottimizzatore Adam o SGD con momentum ($lr = 0.001$) e funzione di costo Cross-Entropy per almeno 30 epoche, monitorando l'andamento su un validation set estratto dal training set (pari al 15% dei dati). Si implementi una logica di model checkpoint che salvi su disco esclusivamente il miglior modello rispetto alla minima validation loss (val_loss). punti 10
--	---

4.	Confrontare i risultati dei due classificatori (il modello Random Forest ottimizzato e la Rete Conv1D migliore ripristinata dal checkpoint) calcolando e visualizzando graficamente sul test set: • La matrice di confusione per ciascun classificatore; • Le curve ROC secondo la strategia One-vs-Rest (OvR) per ciascuna delle 7 classi e la curva media aggregata di tipo Micro-average; • I rispettivi valori di AUC (Micro e Macro). punti 4
-----------	---

TOTALE: punti /30

Data:	Allievo:	Matricola:
--------------	-----------------	-------------------

[1]

Università degli Studi di Palermo Dipartimento di Ingegneria <i>Direttore: prof. Antonino Valenza</i>	dipartimento di ingegneria unipa
---	---

Regole della prova scritta

Di seguito si riportano le regole da seguire e le caratteristiche della prova ai fini della valutazione:

1. La durata complessiva della prova è pari a due ore e prevede una serie di quesiti che approfondiscono diversi aspetti dello stesso problema: ognuno sarà libero di dedicare ad ogni quesito il tempo che vorrà.
2. La prova si svolge interamente al calcolatore.
3. L'ambiente di sviluppo predisposto è un environment conda denominato *spyder-env* (o *bigdata-env*), direttamente accessibile da Visual Studio Code.
4. Ai fini dell'avvio dell'ambiente, aprire Visual Studio Code e dal suo file manager selezionare la cartella **BigData** sul Desktop e creare un nuovo notebook per il quale si selezionerà l'ambiente illustrato precedentemente.
5. Sarà consentito consegnare dopo la prima ora di prova.
6. Sarà necessario spegnere e consegnare i dispositivi mobili (smartphone, smartwatch e tablet) alla cattedra prima

dello svolgimento della prova.

7. La navigazione internet dalle postazioni sarà bloccata, in generale, e consentita solo verso i siti di documentazione delle librerie ed il repository delle slide in pdf.
8. Il docente distribuirà copia digitale del compito ed eventuali data set direttamente dalla propria postazione ovvero tramite penna USB e allo stesso modo raccoglierà gli elaborati di programmazione.
9. Il candidato consegnerà comunque il presente foglio datato e con l'indicazione del nome e del numero di matricola.
10. Ai fini del calcolo del voto finale della prova, il valore massimo di ciascun quesito è riportato in calce allo stesso.
La prova riceverà una valutazione pari alla somma dei voti riportati in ciascun quesito. Si precisa che il docente attribuirà ad ogni quesito una votazione non binaria, cioè non tutto il valore oppure 0, ma valuterà la correttezza formale dell'elaborato, il rigore metodologico dell'approccio teorico e l'originalità delle soluzioni proposte per attribuire una votazione nel range definito dal valor massimo del quesito.

Data:	Allievo:	Matricola:
--------------	-----------------	-------------------